

# Back from the Future

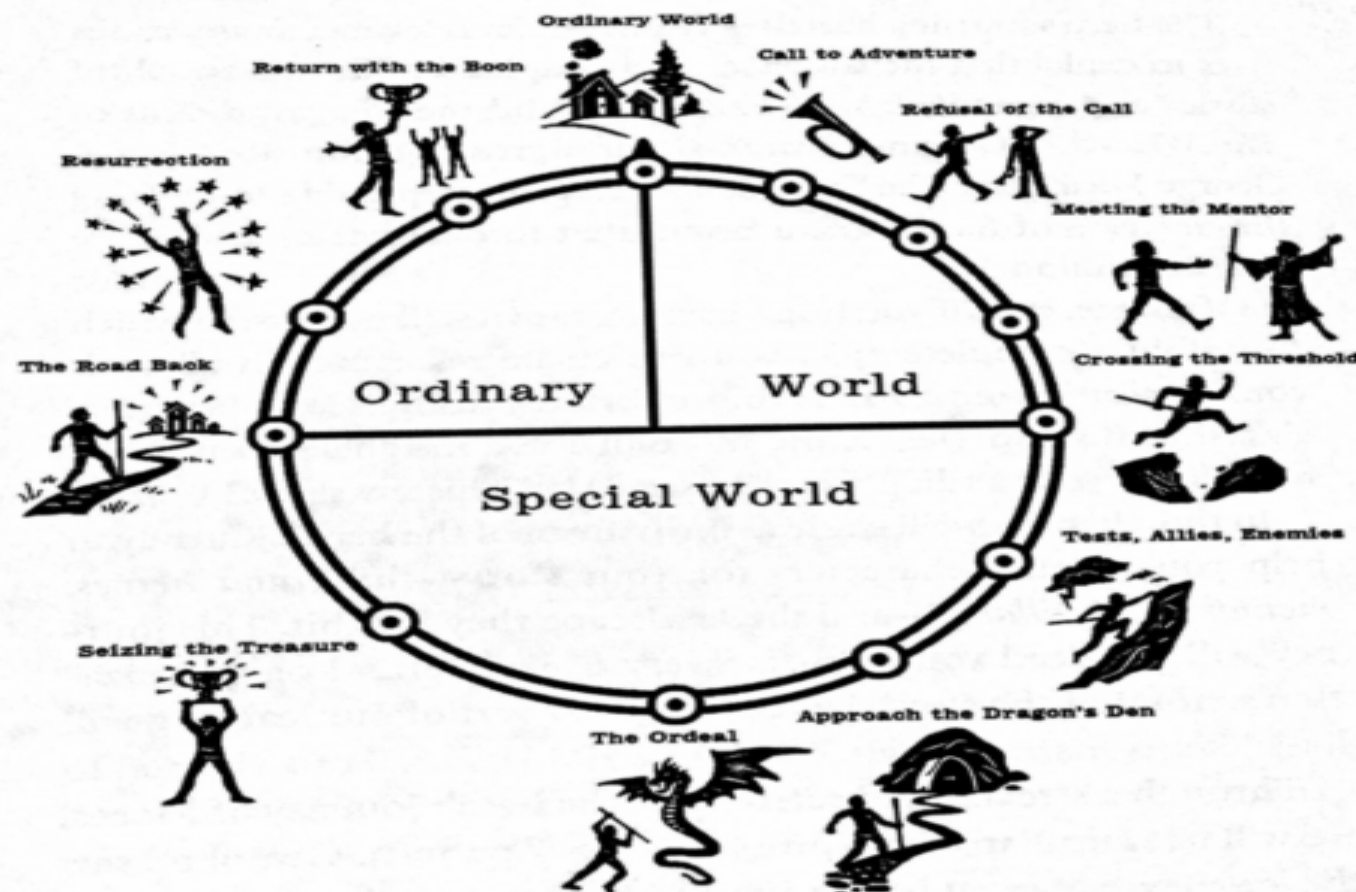
## 2023

# Agenda

- 1) Motivación
- 2) Experimentación
- 3) Test Estadístico para la comparación de Modelos Predictivos

## The 12 Phases Mapped to The Context

### Joseph Campbell's Hero's Journey Map



#### 1st Act (The Known)

1. The Ordinary World (*Comfort Zone*)
2. Call to Adventure (*Stressor*)
3. Refusal of The Call (*Resistance, Fear*)
4. Meeting The Mentor (*Coach, Facilitator*)
5. Crossing The Threshold (*Leadership*)

#### 2nd Act (The Adventure)

6. Tests, Allies, Enemies (*Experiment, Observe*)
7. Approaching The Inner Cave (*Understand, Make Sense*)
8. The Ordeal (*Reflector, Punctuation Point*)
9. Seize The Reward (*Revelation, Knowledge Gained*)

#### 3rd Act (Chance to Make It Right)

10. The Road Back Home (*Transform, Change*)
11. Resurrection, Atonement (*Show Proof*)
12. Return with The Elixir (*Outcome, Kaizen*)

# Capítulo 1

## Motivación

# Episode 1.2 Call to Adventure stressor

The adventure might begin from a blunder, or when a passing phenomenon causes a wandering eye luring the hero from the frequented path ...

Joseph Campbell, *The Hero with a Thousand Faces*, 1949

blunder :/'blʌndə/ *noun* : a stupid or careless mistake

# Motivación mejoras inexplicables






## Leaderboard


[Raw Data](#)[Refresh](#)[Public](#)[Private](#)

The private leaderboard is calculated with approximately 70% of the test data.

#	△	Team	Members	Score	Entries	Last	Join
1	<u>▲ 79</u>	fermonzon1		57.58759	59	2d	
2	<u>▲ 38</u>	joha noval		56.94473	74	8d	
3	<u>▲ 52</u>	Anto Caccianini1		56.89759	88	3d	

# Motivación catástrofes Private Leaderboard

82	▼ 75	MarianoD Marchetta		51.34326	324	2d
83	▼ 62	Anita Ona		50.72182	129	7d
84	▼ 51	Verónica García Río		50.23753	333	3d
85	▲ 9	Damian Quiroga		50.03182	2	1mo
86	▼ 43	Ignacio Dottore		49.55610	125	11h






# Motivación semillas

charlas de café

stream events

May 12



**Hernan Ifran**

3:34 PM

@Gustavo, Que aconseja hacer para salir de ese infierno? Jose esta haciendo el mismo experimento. todo se resume a la semilla

Si esperáramos a que finalice la competencia  
veríamos desconcertantes comentarios  
en Zulip como los que siguen

# Motivación comentarios otros años

"Nunca termine de entender cuál fue mi mejor modelo y que podría haber hecho para que sea mejor."

# Motivación comentarios otros años

"Nunca termine de entender cuál fue mi mejor modelo y que podría haber hecho para que sea mejor."

"...da la sensación de que en realidad estuvimos todo el tiempo en un **casino** jugando a la **ruleta**."

# Motivación comentarios otros años

"Nunca termine de entender cuál fue mi mejor modelo y que podría haber hecho para que sea mejor."

"...da la sensación de que en realidad estuvimos todo el tiempo en un **casino** jugando a la **ruleta**."

"de la nada un modelo al que le **apostas** todo no sirve para nada."

# Motivación comentarios otros años

Un alumno de mitad de tabla propone

"Capaz se me ocurre que los primeros puestos nos expliquen directo que hicieron , para aprender."

# Motivación comentarios otros años

Un alumno de mitad de tabla propone

"Capaz se me ocurre que los primeros puestos nos expliquen directo que hicieron , para aprender."

Un integrante del equipo ganador, responde

"Si supiera, te lo diría."

# Motivación comentarios otros años

Un alumno de mitad de tabla propone

"Capaz se me ocurre que los primeros puestos nos expliquen directo que hicieron , para aprender."

Un integrante del equipo ganador, responde

"Si supiera, te lo diría."

El otro integrante del equipo ganador

"Del Público al Privado subimos 42 posiciones, me cuesta entender por que se produjo tanta diferencia"



## Motivación comentarios otros años

- "a mi me gustaría entender todas las situaciones, no solo los primeros puestos:
  - Los q estaban en el primer puesto en el público pero cayeron muchos puestos en el privado
  - Los que estaban abajo en el público pero en el privado subieron muchos puestos"

## Motivación comentarios otros años

- "a mi me gustaría entender todas las situaciones, no solo los primeros puestos:
  - Los q estaban en el primer puesto en el público pero cayeron muchos puestos en el privado
  - Los que estaban abajo en el público pero en el privado subieron muchos puestos"
- "realmente me cuesta expresar lo mucho que me he esforzado, y la poca esperanza que tengo de encontrar una solución verdadera (y no depender únicamente del azar dentro de un margen de error)"

Motivación comentarios otros años

"... no puedo conectar todo el análisis hecho con los resultados de Kaggle."

# Motivación comentarios otros años

"... no puedo conectar todo el análisis hecho con los resultados de Kaggle."

"Me voy a quedar con la imagen del Publico!!! (Ojos que no ven.....)"

## Motivación comentarios otros años

"... no puedo conectar todo el análisis hecho con los resultados de Kaggle."

"Me voy a quedar con la imagen del Publico!!! (Ojos que no ven.....)"

"Yo tuve una gran frustración al ver en el privado la verdad, sigo pensando hoy qué métodos podría haber utilizado para que las señales, por las que elegí el que elegí, me haya dado el correcto."

# Motivación comentarios otros años

"a pesar que las ultimas dos semanas le dediqué todo mi tiempo libre, me decepcionaron mis resultados en el Private. Pero lo tomo como un aprendizaje...

Lo que me desvela es : en modelos de mi trabajo ¿cómo **reducir la variabilidad** de la predicción?, ya que seguramente me está sucediendo y recién esta materia me abrió los ojos.  
¿En cuántos modelos habré tenido mala suerte por el azar?"

# Motivación

nombres de equipos Kaggle otros años

- Monos que apretan palancas
- Team Suerte y Overfitting



¿Cuánto puede variar la ganancia de un modelo?

¿Qué relación hay entre la ganancias medidas en 5-fold cross validation, Public y Private?



¿Cuánto puede variar la ganancia de un modelo?

¿Qué relación hay entre la ganancias medidas en 5-fold cross validation, Public y Private?

¿ Si un modelo M1 da más ganancia que M2 en 5-fold cross validation, también es mejor en el Public Leaderboard? ¿ y en el Private?

En el mundo real, sin el beneficio de Kaggle  
¿Qué relación hay entre la ganancias medidas en  
5-fold cross validation  
y las ganancias que obtendré en el futuro?

En el mundo real, sin el beneficio de Kaggle  
¿Qué relación hay entre la ganancias medidas en  
5-fold cross validation  
y las ganancias que obtendré en el futuro?

¿ Si un modelo M1 da más ganancia que M2 en  
5-fold cross validation en entrenamiento,  
también es mejor M1 que M2 en los datos del futuro ?

# Overfitting the Leaderboard in Ernst & Young Data Science Competition 2019

And subsequently losing 8000 USD + a ticket to New York.



Ilham Firdausi Putra · [Follow](#)

Published in HMIF ITB Tech · 7 min read · Jul 15, 2019

## What Went Wrong?

It was the cornerstone of an inept data scientist, stemming from a complete lack of experience. The main ingredient of a classic shake-up between public and private leaderboard score:

We did not trust our cross-validation score

— and the result was catastrophic. We had overfitted the public leaderboard.

5-fold cross validation en los datos de entrenamiento, ¿resuelve realmente el problema ?

# Capítulo 2

## Experimentación

Para entender lo que está sucediendo  
se realizaron dos experimentos  
en meses antiguos del dataset  
utilizando una función de ganancia menor

al final se compararán dos modelos

Experimento

*Modelo Simple*

# Experimento *Modelo Simple*    Objetivo

Objetivo: analizar la variabilidad de un modelo *fijo* a partir de muy buenos parámetros que entrena tan solo en un único mes, noviembre-2020  
Finalmente, se observa el comportamiento de **volver a generar cada vez** el modelo con 125 distintas semillas en:

- 5-fold cross validation
- Public Leaderboard
- Private Leaderboard



# Experimento *Modelo Simple* jugando con la semilla

¿Cuál es la variabilidad de las ganancias de LightGBM si se entrena en el mismo dataset, se dejan los hiperparámetros fijos, pero se cambia unicamente la semilla (que sería lo mismo que reordenar al azar las columnas del dataset) ?

o sea, ¿Cuál es la variabilidad inherente de un modelo, generado en este caso con LightGBM ?

Debido al hiperparámetro `feature_fraction` entrenar con distinta semilla genera distintos modelos en LightGBM

# Experimento *Modelo Simple* resultados

Cambiando las semillas las corridas jamás dan la misma ganancia

- ni en 5-fold cross validation,
- ni en el Public
- ni en el Private Leaderboard

Se graficará la función de distribución de probabilidad de esa variable aleatoria (la ganancia).

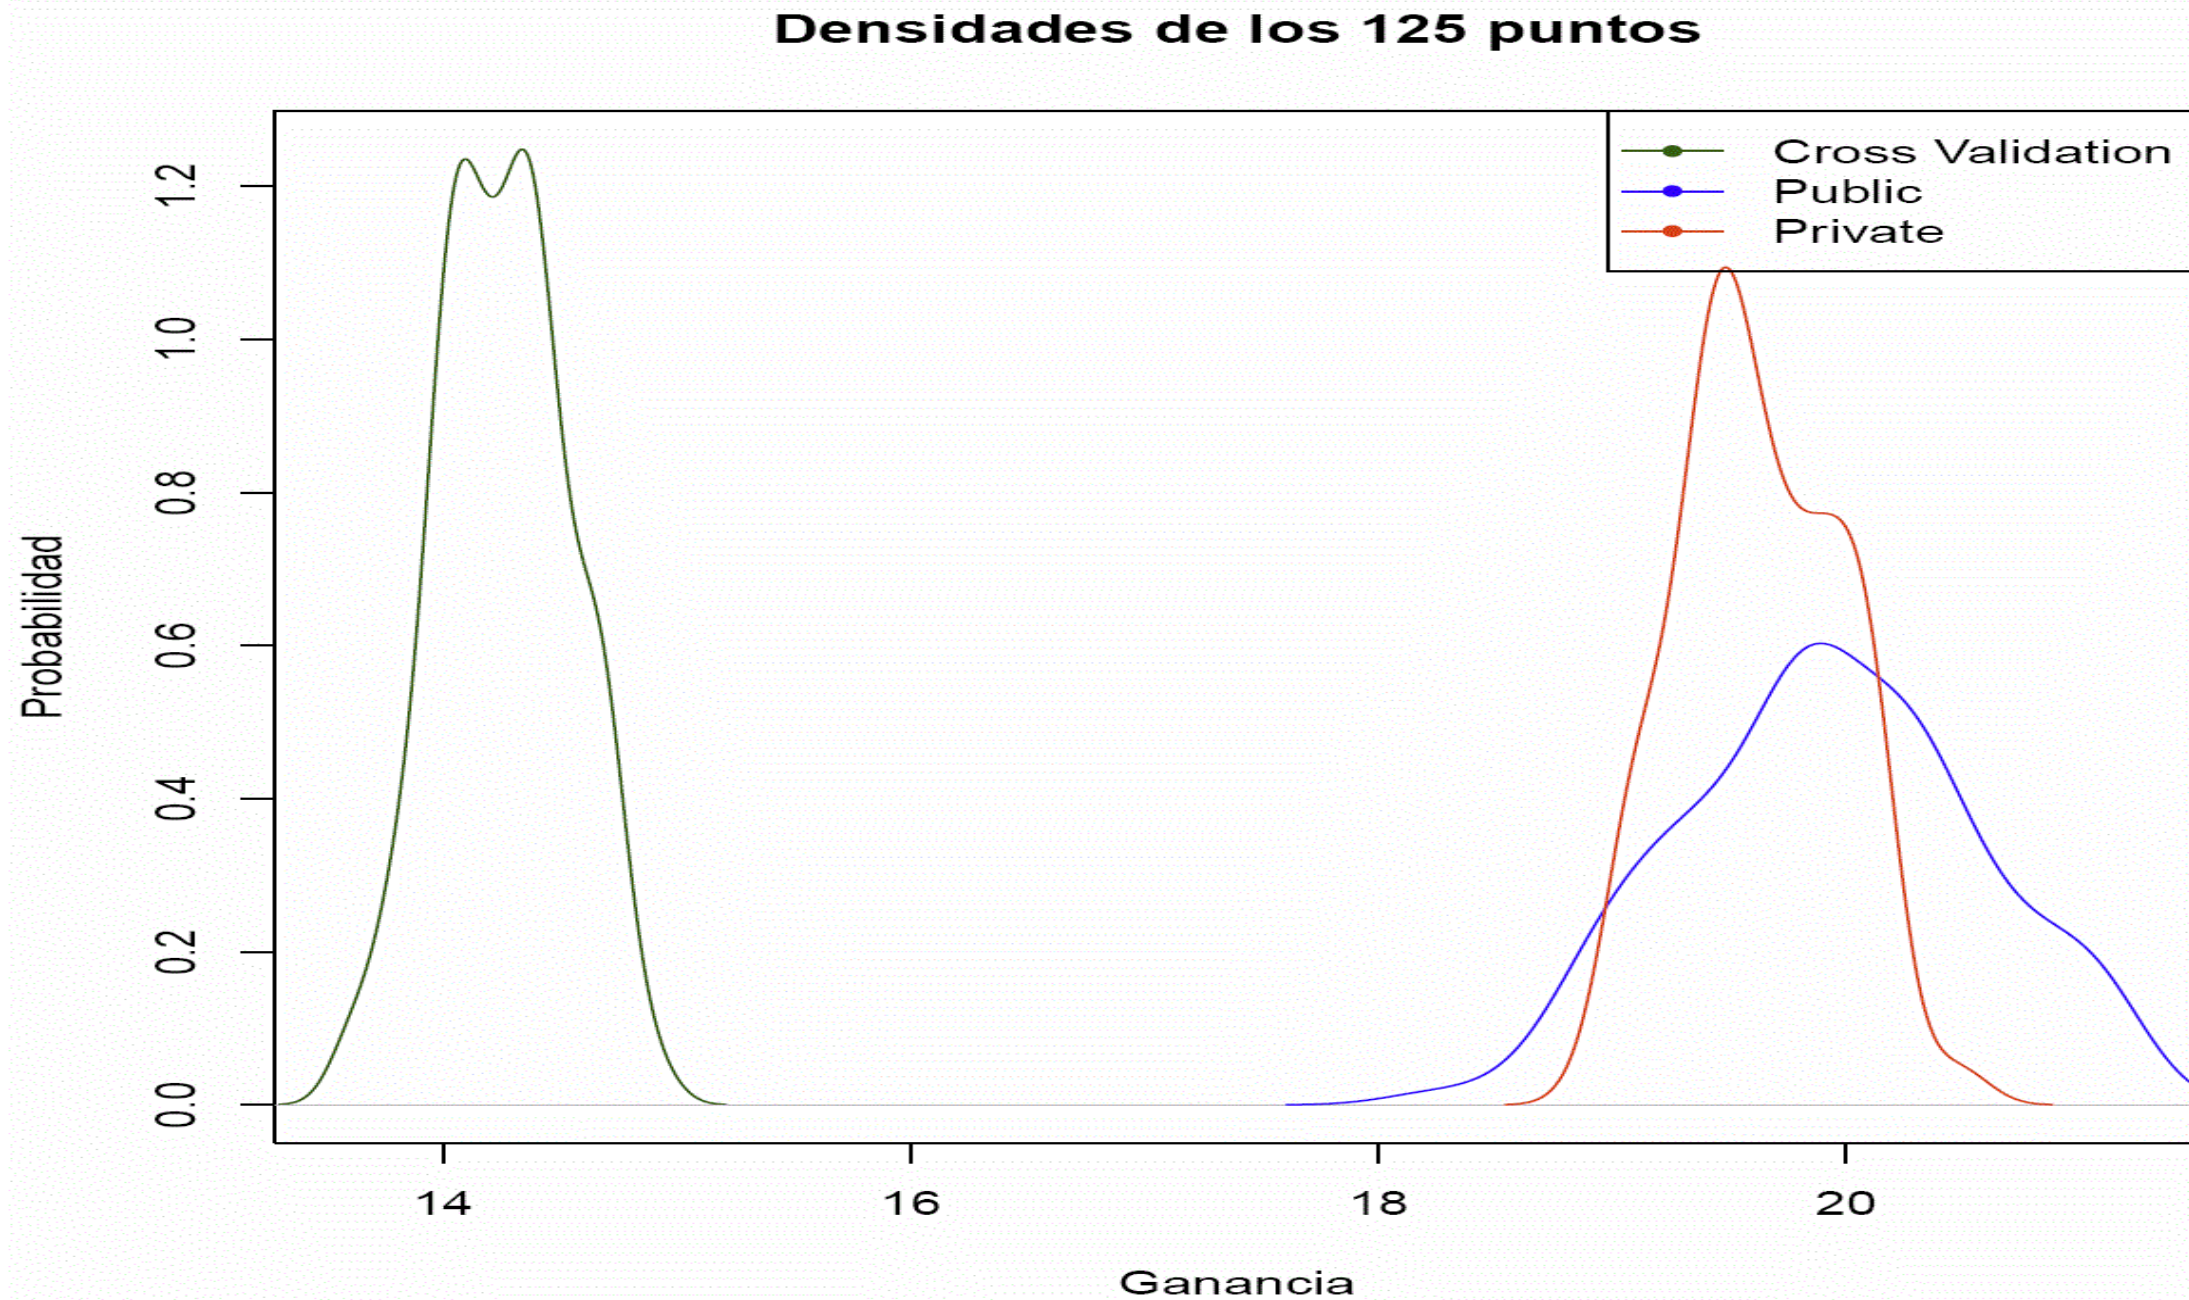
# Experimento *Modelo Simple* resultados

Estamos entrenando en noviembre-2020, el futuro es enero-2021, y la función ganancia es menor a la usada en el curso de 2023  
Por lo anterior veremos ganancias inferiores, pero es solo un tema de escala.

# Experimento *Modelo Simple* resultados

Ganancia	mean	sd
Cross Validation	14.3	0.28
Public	19.9	0.63
Private	19.6	0.34

# Experimento *Modelo Simple* resultados

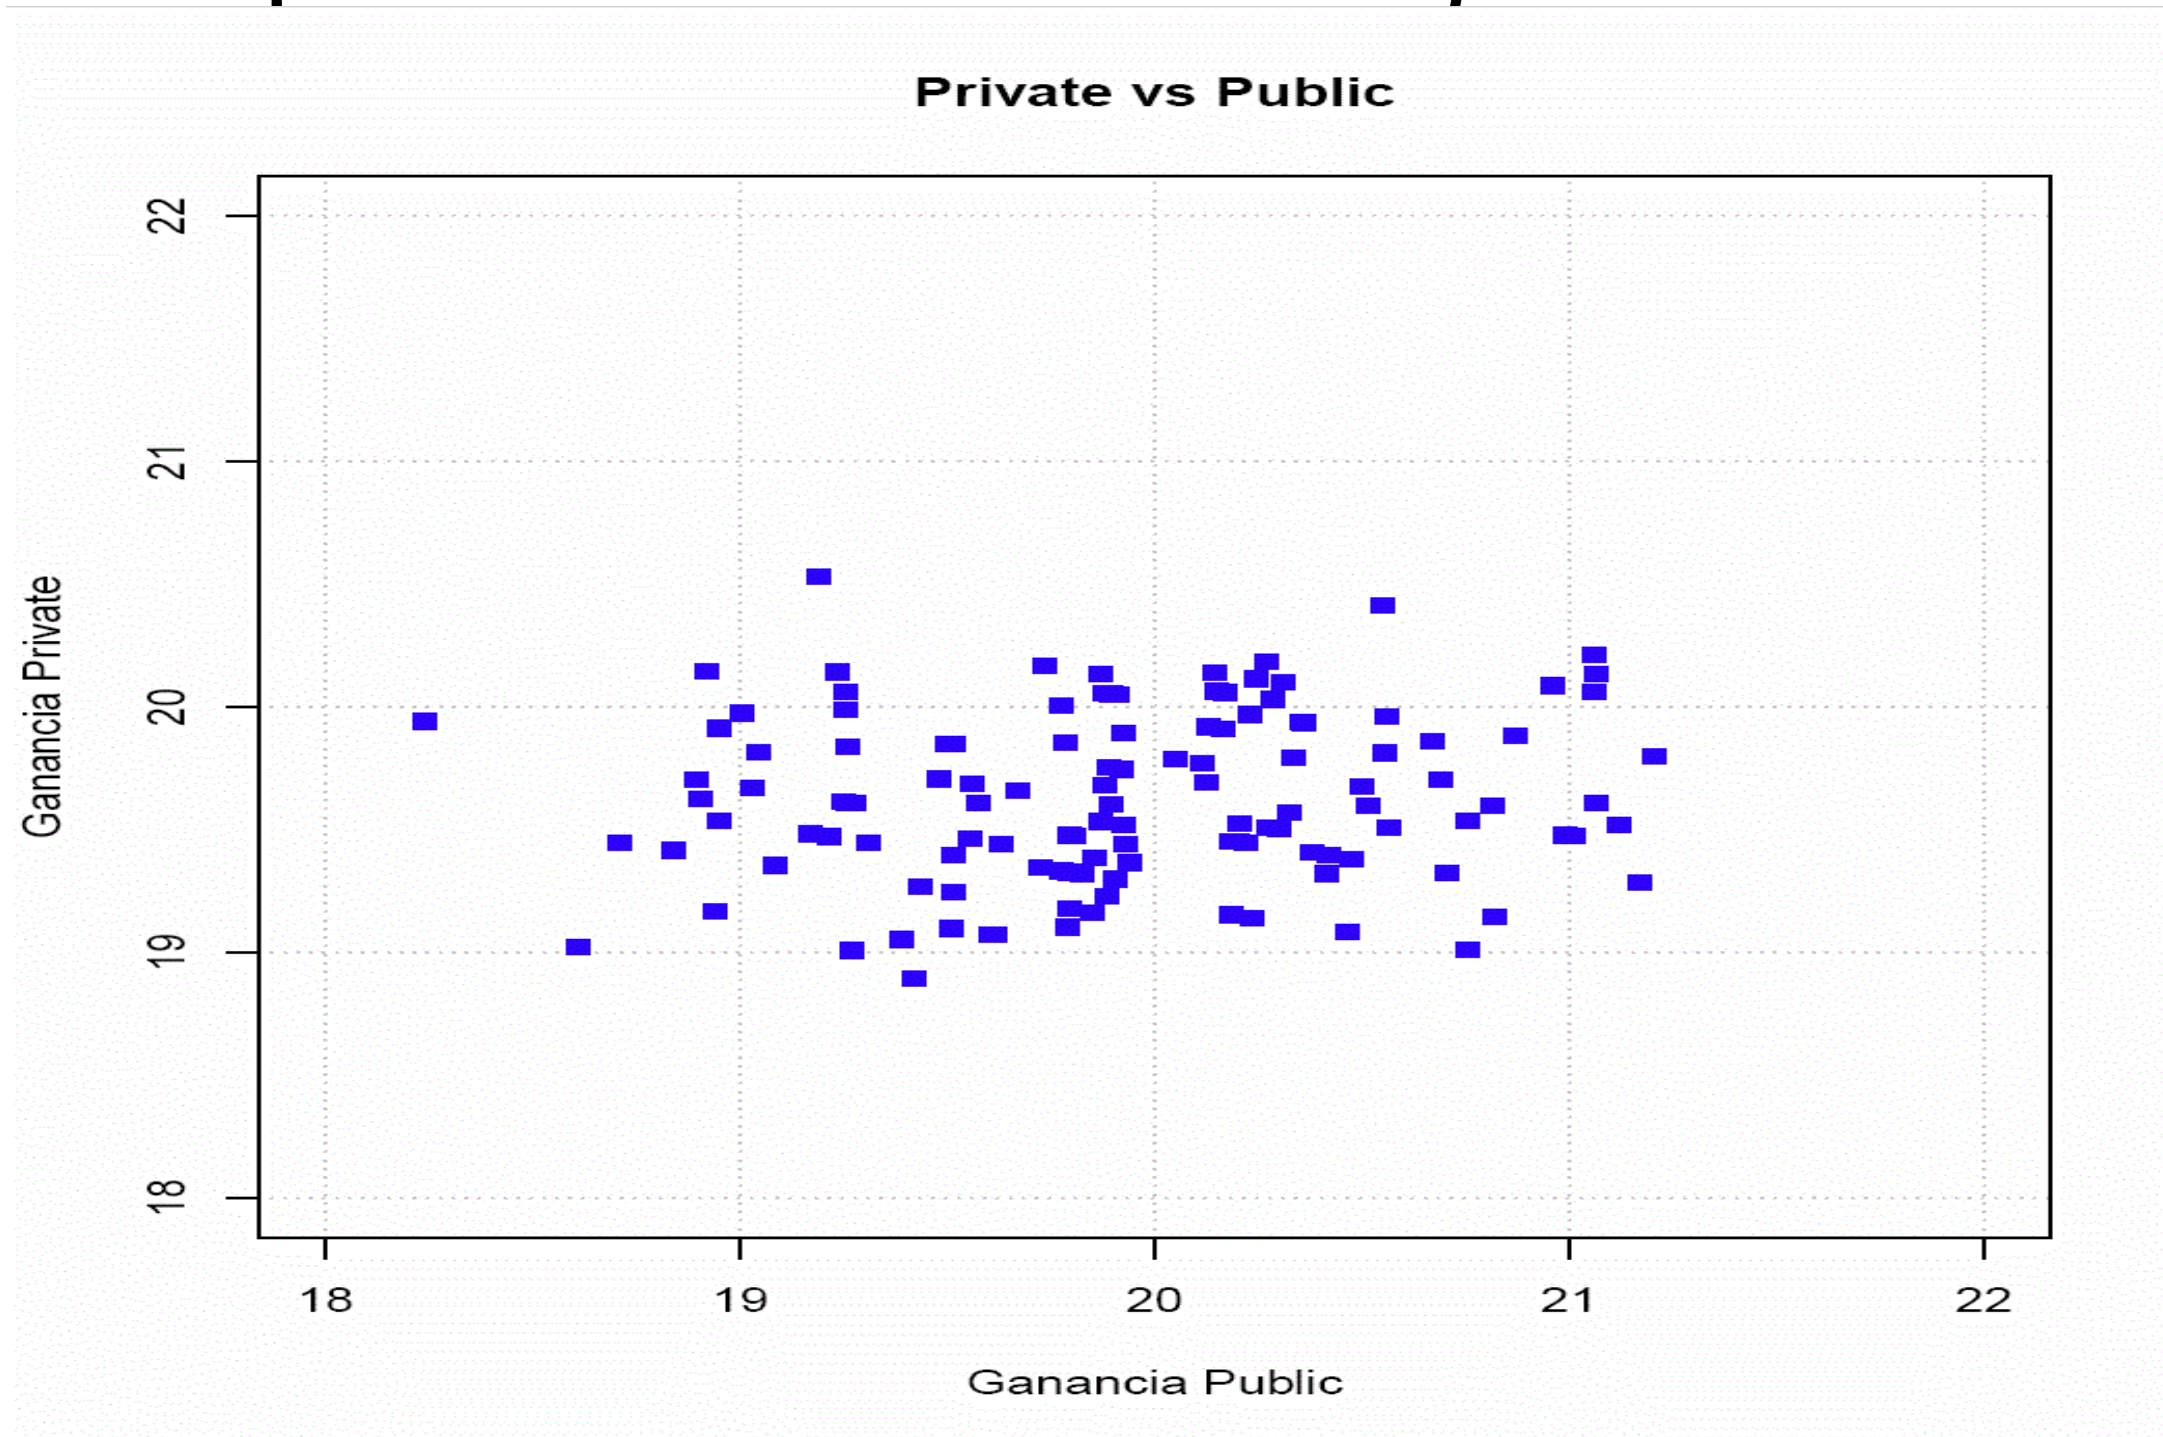


- En el mes de entrenamiento hubo menos BAJA+2 por eso las ganancias son menores, en el entorno a los 15 M
- En el mes de aplicación hubo más BAJA+2, y las ganancias son mayores.
- La varianza de los datos depende de la cantidad de registros del dataset
- `#Public < #Private < #mes_completo`


¿El Public es buen predictor de cómo me va a ir en el Private ?

¿La mejor semilla del Public da el mejor resultado en el Private?

# Experimento *Modelo Simple* aleatoriedad







Estamos en el caso de “No Correlation”

¿El Public es buen predictor de cómo me va a ir en el Private ?

Definitivamente no !

La mejor ganancia del Public no es la mejor ganancia del Private

¿La mejor semilla del Public da el mejor resultado en el Private?


No !

El Public Leaderboard no sirve como señal (para este nivel de detalle)

La bibliografía dice enfáticamente  
no confiar en el Public Leadeboard

pero indica confiar en el  
5-fold Cross Validation


# Experimento *Modelo Simple* aleatoriedad



¿5-fold cross validation es buen predictor de como me va a ir en el Private ?


Para total sorpresa : NO !

# Experimento *Modelo Simple* aleatoriedad



¿ Cómo interpretar lo que estamos viendo?


# Experimento *Modelo Simple* aleatoriedad





# Experimento *Modelo Simple* aleatoriedad

3D (scatterplot3d) Plot of a Bivariate Gaussian Distribution  
with  $\mu_1=0$  ,  $\mu_2=0$  ,  $\sigma_{11}=1$  ,  $\sigma_{22}=4$  ,  $\sigma_{12}=0$



## Experimento *Modelo Simple* conclusión

- Los resultados 5-fold cross validation, Public y Private poseen una distribución *quasi* normal, y en caso que solo cambie la semilla son independientes entre si.
- No se puede saber si se va a estar por encima o por debajo de la media en los datos del futuro, por más que para el dataset que conozco la clase ese semilla tenga una ganancia por encima de la media.

¿Cómo comparo dos modelos distintos, que fueron generados con datasets e hiperparámetros diferentes?

# Experimento

## *Modelo Power*

# Experimento *Modelo Power*    Objetivo

Objetivo: analizar la variabilidad de un modelo *fijo* que utiliza diez meses [202001, 202011] – 202006 dataset con `lag1` y `delta1`

Finalmente, se observa el comportamiento de **regenerar** el modelo con 125 semillas en:

- 5-fold cross validation
- Public Leaderboard
- Private Leaderboard

# Experimento *Modelo Power*

Al dataset original ahora se le agregan los **lags y delta lag de orden 1**, además de corregir las variables *rotas*. Se buscan los hiperparámetros óptimos del LightGBM con una Optimización Bayesiana, train=[202001,202010]  
test=[202011]

Finalmente, se observa el comportamiento de **regenerar** el modelo con distintas semillas en:

- Testing , [202011]
- Public Leaderboard
- Private Leaderboard

# Experimento *Modelo Power* dataset

Para una variable, el lag de orden 1, **lag1** es el valor de esa variable el mes anterior. Si el mes anterior el registro no está en la base de datos, se asigna NA.


El **delta1** para una variable es el valor en el mes actual de la variable menos su valor el mes anterior.

# Experimento Modelo Simple vs Power


Métrica	<i>Modelo Simple</i>	<i>Modelo Power</i> 10 meses
Cross Validation	14.3	124.7
Public	19.9	21.2
Private	19.6	20.6



# *Modelo Power*    aleatoriedad



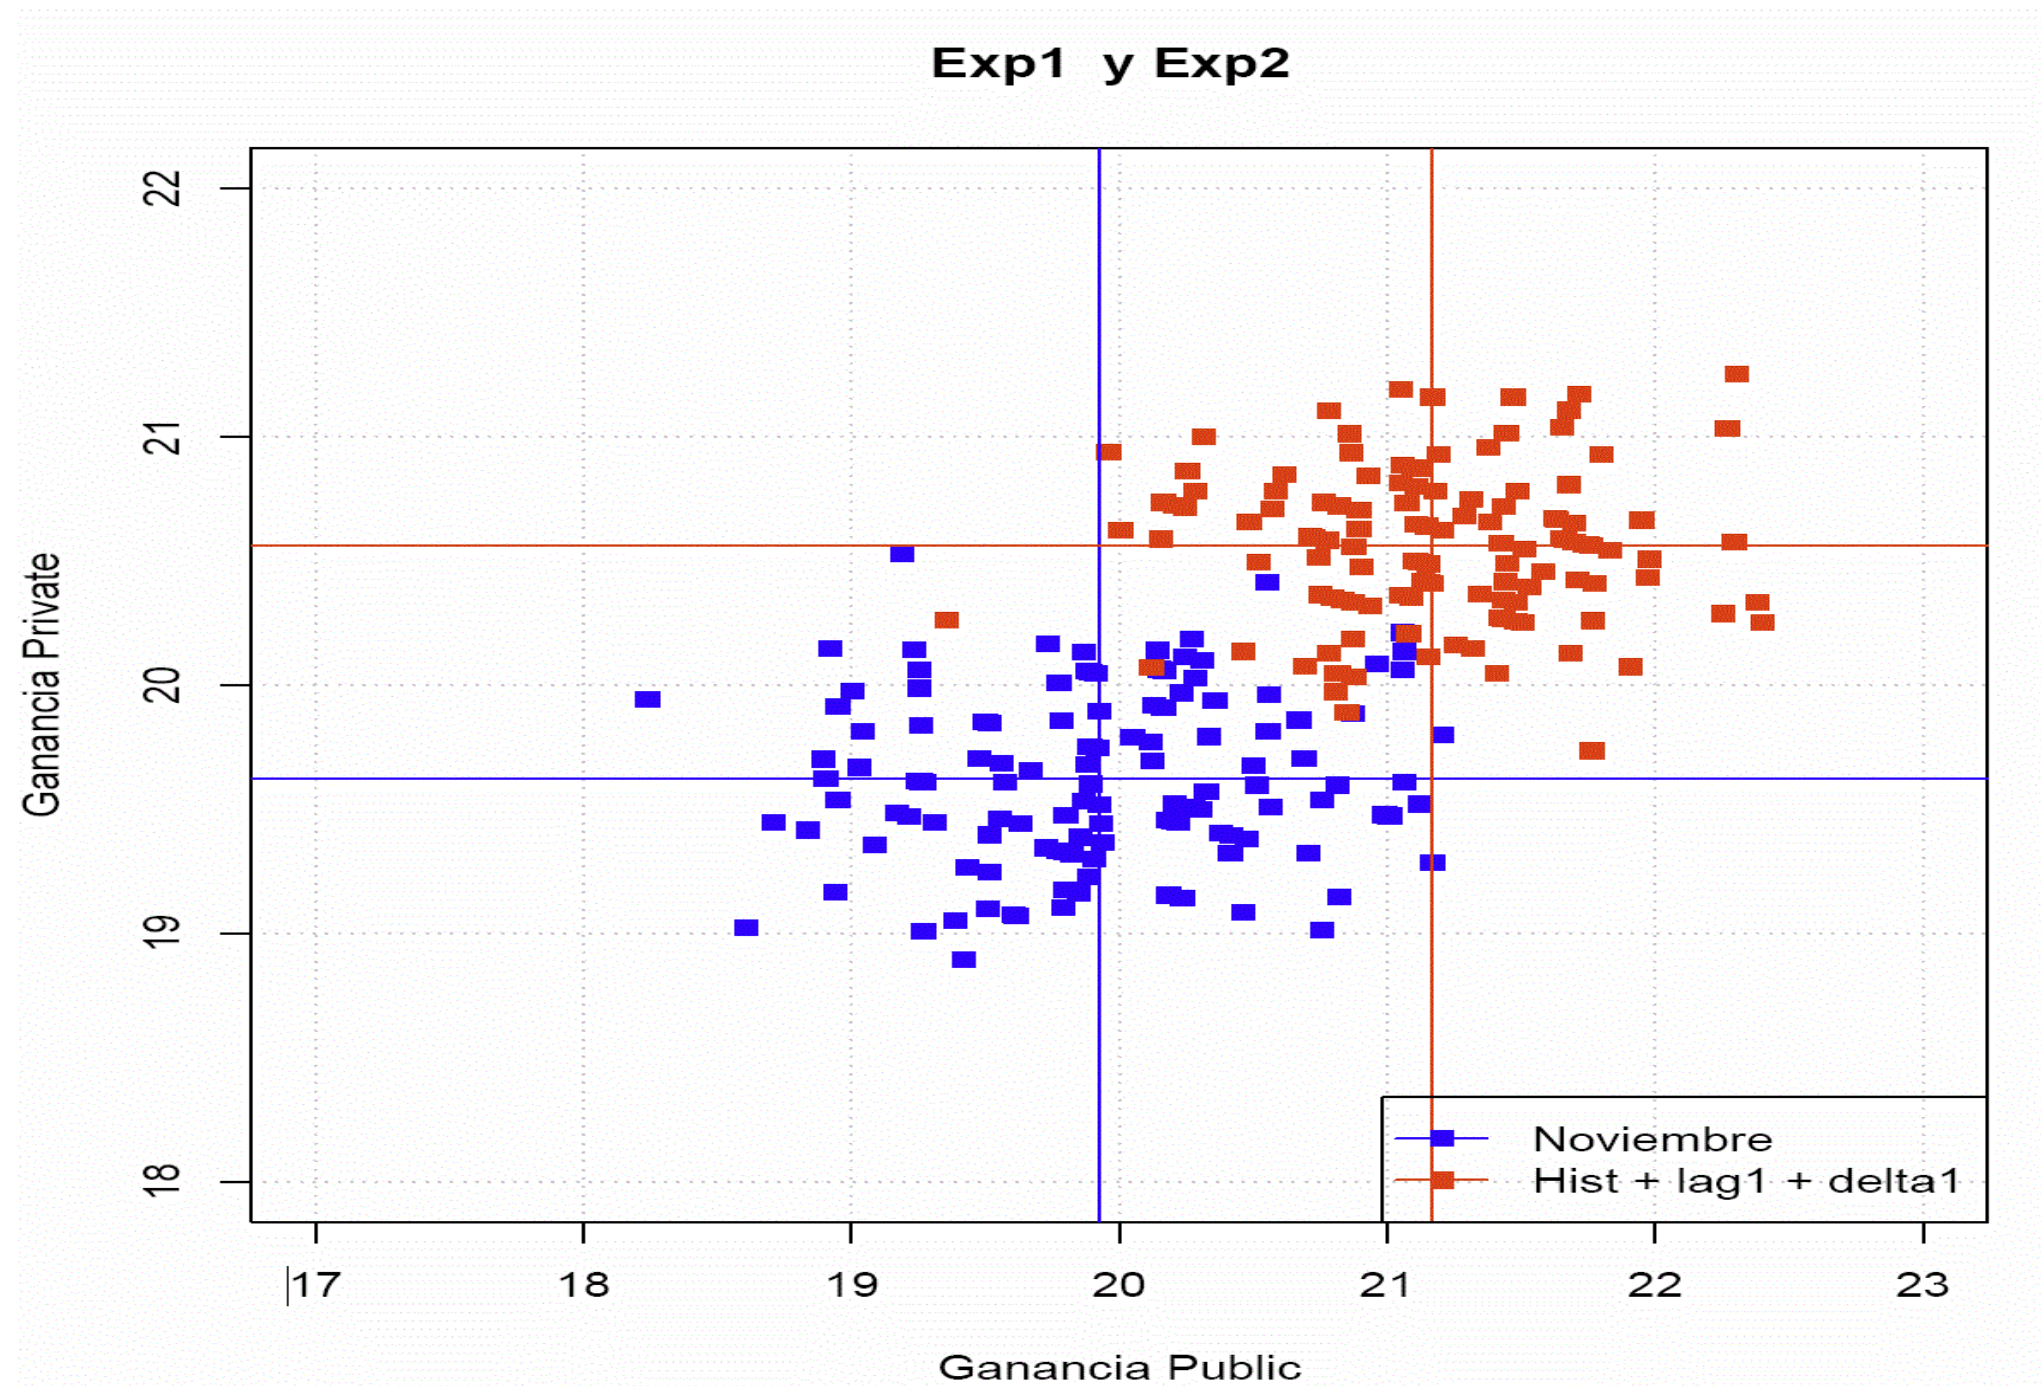
# *Modelo Power*    aleatoriedad



Finalmente, la comparación entre los dos  
experimentos



# *Modelo Power (rojo) vs Modelo Simple (azul)*



## Conclusion General:

El *Modelo Power* (color rojo) es mejor que el *Modelo Simple* (color azul)

Sin embargo, no se cumple que todas las ganancias del modelo rojo dan mejores ganancias que el modelo azul.

En el ejemplo eso es verdad para el 92% de los casos.

## Conclusion General:

La comparación entre dos modelos predictivos M1 y M2 viene acompañada de una probabilidad.

Siempre se debe decir por ejemplo

$\text{metrica}(M2) > \text{metrica}(M1)$

con una probabilidad  $p$

en el caso que  $p$  sea cercana a 0.5 hace falta un mayor número de observaciones para determinar el sentido de la desigualdad.

# Capítulo 3

## Test Estadístico

# Comparación estadística

Demsar, Janez. *Statistical Comparisons of Classifiers over Multiple Data Sets*, Journal of Machine Learning Research 7 (2006) 1–30, 2006

Wilcoxon signed rank test

en lenguaje R

```
wilcox.test( ganancias1, ganancias2)
```



# Comparación estadística

En los Experimentos Colaborativos se presentó la dificultad de determinar si el método A era superior al método B, dando cada uno de ellos una ganancia distinta para cada semilla, curvas que se cruzaban, etc

¿ Cuántas semillas es necesario utilizar para determinar si un modelo es superior a otro? Evidentemente es un número menos a 125 semillas (al menos para este caso)

*Modelo Simple, ganancias*    20.55    19.78

*Modelo Power, ganancias*    21.95    20.29

```
> wilcox.test( c(20.55, 19.78), c(21.95, 20.29) )
```

```
Wilcoxon rank sum exact test
```

```
data: c(20.55, 19.78) and c(21.95, 20.29)
```

```
W = 1, p-value = 0.6667
```

```
alternative hypothesis: true location shift is not equal to 0
```

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3			
4			
5			
6			
7			
8			
9			
10			
11			
12			
13			

*Modelo Simple, ganancias*    20.55    19.78    20.76

*Modelo Power, ganancias*    21.95    20.29    20.87

```
> wilcox.test( c(20.55, 19.78, 20.76), c(21.95, 20.29, 20.87) )
```

```
Wilcoxon rank sum exact test
```

```
data: c(20.55, 19.78, 20.76) and c(21.95, 20.29, 20.87)
```

```
W = 2, p-value = 0.4
```

```
alternative hypothesis: true location shift is not equal to 0
```

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4			
5			
6			
7			
8			
9			
10			
11			
12			
13			

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5			
6			
7			
8			
9			
10			
11			
12			
13			

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5	19.62	21.68	0.032
6			
7			
8			
9			
10			
11			
12			
13			

◀ 5 valores de  
cada experimento  
alcanzan para  
determinar  
gan(Power) > gan(Simple)

p-value < 0.05

Con 5 semillas alcanzaba para darnos cuenta  
que el *Modelo Power* es superior a *Modelo Simple*  
cuando el p-value se hizo menor a 0.05



qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5	19.62	21.68	0.032
6	20.25	20.87	0.009
7			
8			
9			
10			
11			
12			
13			

◀ 5 valores de  
cada experimento  
alcanzan para  
determinar  
 $\text{gan(Power)} > \text{gan(Simple)}$   
  
p-value < 0.05

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5	19.62	21.68	0.032
6	20.25	20.87	0.009
7	19.79	21.51	0.002
8			
9			
10			
11			
12			
13			

◀ 5 valores de  
cada experimento  
alcanzan para  
determinar  
 $\text{gan(Power)} > \text{gan(Simple)}$

p-value < 0.05

qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5	19.62	21.68	0.032
6	20.25	20.87	0.009
7	19.79	21.51	0.002
8	19.24	20.79	0.0006
9			
10			
11			
12			
13			

◀ 5 valores de  
cada experimento  
alcanzan para  
determinar  
gan(Power) > gan(Simple)

p-value < 0.05


qty	<i>Modelo Simple</i>	<i>Modelo Power</i>	Wilcoxon p-value
1	20.55	21.95	1.000
2	19.78	20.29	0.667
3	20.76	20.87	0.400
4	18.95	21.05	0.114
5	19.62	21.68	0.032
6	20.25	20.87	0.009
7	19.79	21.51	0.002
8	19.24	20.79	0.0006
9	20.31	20.91	0.002
10	18.91	21.44	0.0005
11	20.22	20.59	0.0003
12	20.87	21.32	0.0001
13	19.93	21.48	0.00003

◀ 5 valores de  
cada experimento  
alcanzan para  
determinar  
gan(Power) > gan(Simple)

p-value < 0.05

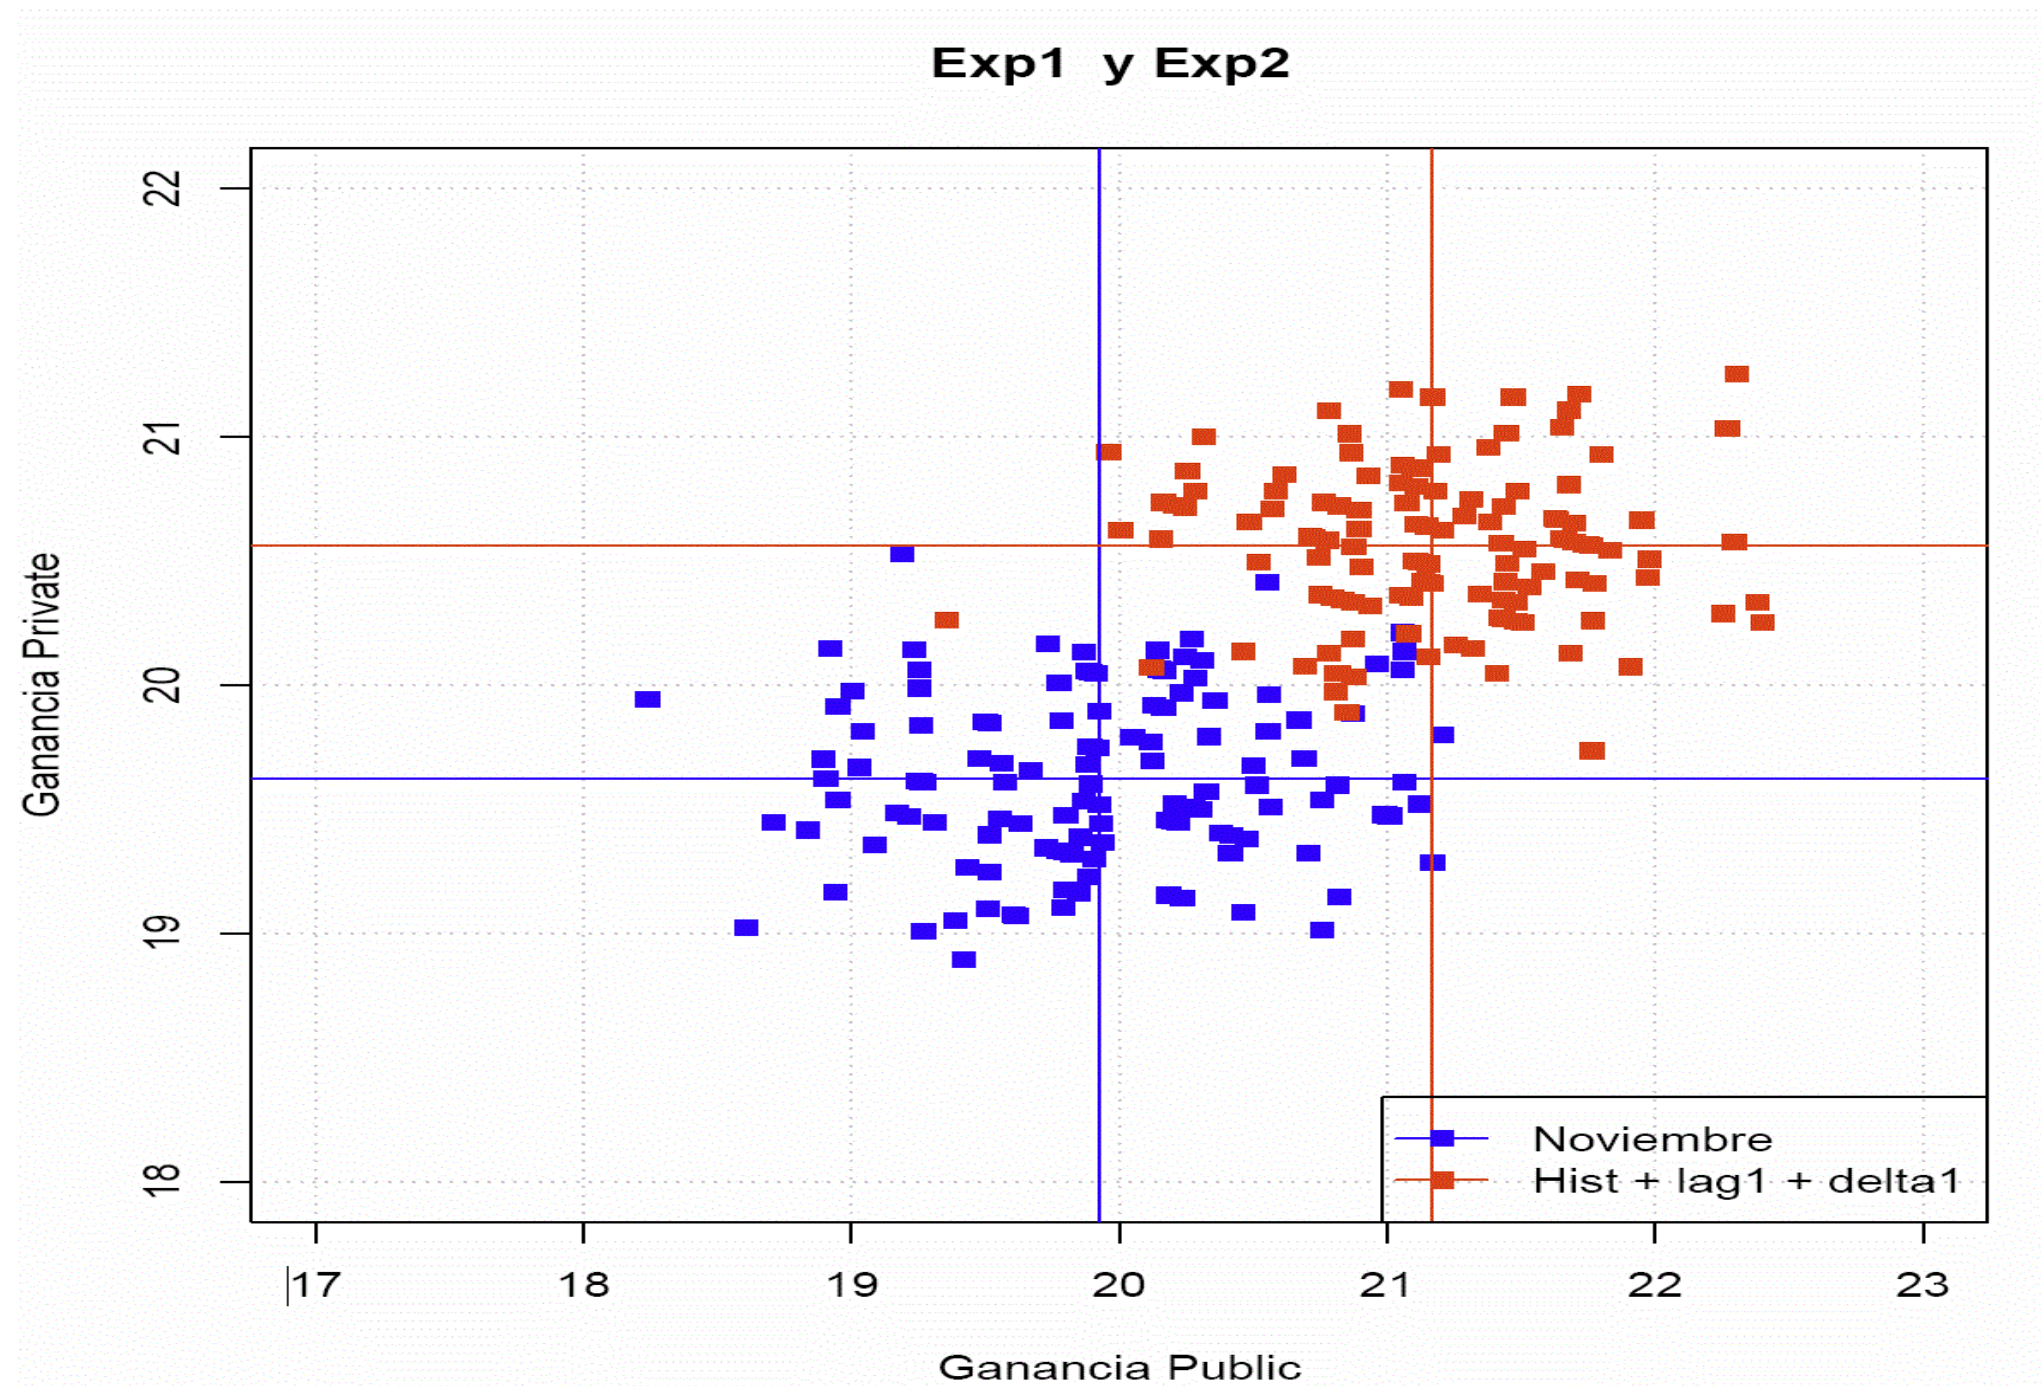
El p-value no necesariamente es  
monótonamente decreciente  
en el paso 9 aumentó con respecto al paso 8

# *Modelo Power (rojo) vs Modelo Simple (azul)*





# *Modelo Power (rojo) vs Modelo Simple (azul)*



The End



¿ The End ?

¿ Vamos a permitir, en esta asignatura  
que un test, una receta de la Estadística Clásica  
tenga la última palabra ?

# Capítulo 4

## Semillerío

Este no es el fin de la historia !

Porque aunque el modelo entrenado en datos históricos con el feature engineering, el *Modelo Power*, aún puedo obtener de 19.74 a 21.25 en el Private Leaderboard

Estoy expuesto a demasiada variabilidad

La teoría dice que debo ensamblar modelos lo más distintos posibles, evitar la endogamia

# A Gentle Introduction to Ensemble Diversity for Machine Learning

by Jason Brownlee on May 14, 2021 in Ensemble Learning



Ensemble learning combines the predictions from machine learning models for classification and regression.


We pursue using ensemble methods to achieve **improved predictive performance**, and it is this improvement over any of the contributing models that defines whether an ensemble is good or not.

A property that is present in a good ensemble is the diversity of the predictions made by contributing models. Diversity is a slippery concept as it has not been precisely defined; nevertheless, it provides a useful practical heuristic for designing good ensemble models.

In this post, you will discover **ensemble diversity** in machine learning.

After reading this post, you will know:

- A good ensemble is one that has better performance than any contributing model.
- Ensemble diversity is a property of a good ensemble where contributing models make different errors for the same input.
- Seeking independent models and uncorrelated predictions provides a guide for thinking about and introducing diversity into ensemble models.



## Episode 2.6 Apotheosis

Once we have broken free of the prejudices of our own provincially limited ecclesiastical, tribal, or national rendition of the world archetypes, it becomes possible to understand that the supreme initiation is not that of the local motherly fathers, who then project aggression onto the neighbors for their own defense.

Joseph Campbell, *The Hero with a Thousand Faces*, 1949



Sin embargo, como la naturaleza de esta asignatura es *cuestionar ideas que otros pregonan como ciertas*, viene un experimento que no se nos puede negar, en lugar de calcular la ganancia para cada modelo y encomendarme a la "suerte" ya que ni **Testing con 5-fold cross validation** ni el **Public Leaderboard** son una señal

# Ensemble Semilleros

# Método Semillerio

Entreno con los mismos hiperparámetros,  
cambiando solamente la semilla en cada iteración

y PROMEDIO las probabilidades de los modelos

`src/workflow-semillerio/z799_ZZ_final-semillerio.r`

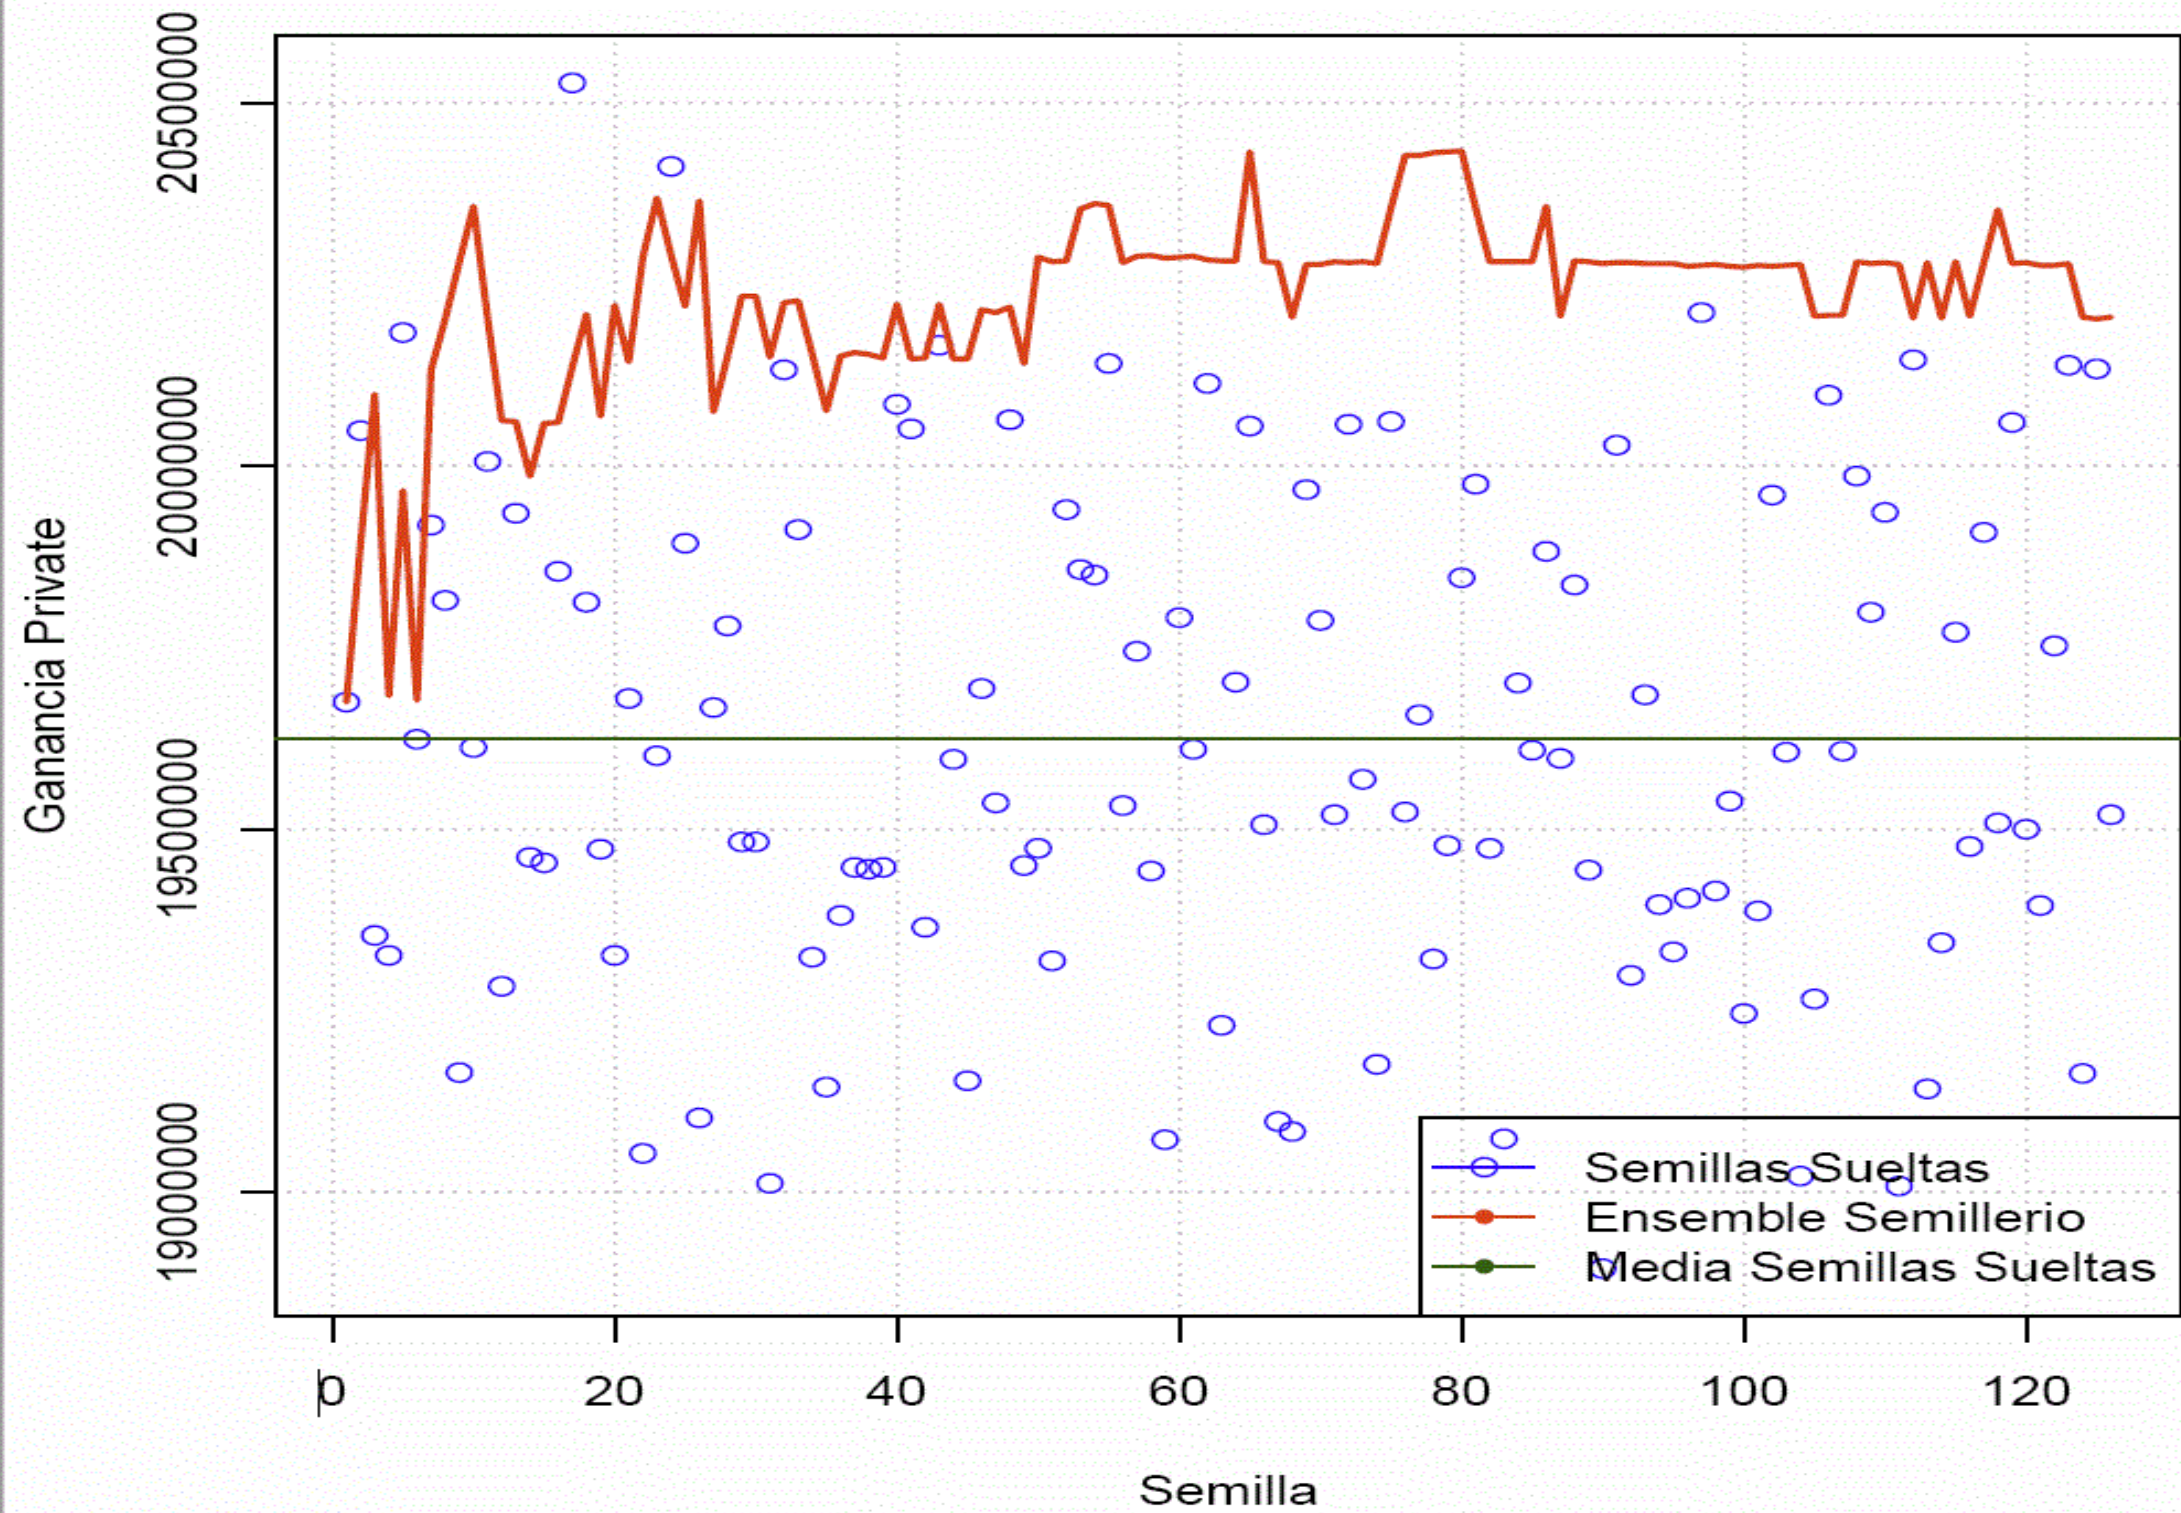
# Método Semillerio

Es un ensemble de LightGBMs, donde lo único que cambia es la semilla.

No hay diversidad en esos modelos, son “clones”.


¿Cómo funcionará esto que va contra las buenas prácticas de la diversidad de los *modelos base* en un ensemble?

Semillero de *Modelo Simple* , 11000 envíos





Semillero de *Modelo Power* , 11000 envíos



El ensemble de LightGBMs  
Supera al 95% de los LightGBMs individuales

Efectos de la ensemble de modelo final <b>promediando</b> sus probabilidades Private Leaderboard				
	<i>Modelo Simple</i>		<i>Modelo Power</i>	
modelos acumulados	ganancia media	desvio estandar	ganancia media	desvio estandar
1	19.64	0.35	20.7	0.27
5	20.04	0.23	21.0	0.19
10	20.09	0.20	21.1	0.15
20	20.19	0.16	21.1	0.10
50	20.21	0.10	21.2	0.06

\$ 500k adicionales en Experimento DOS, de 20.7 a 21.2 , solo con semillero, nada mal ...  
y principalmente con mucha menos varianza

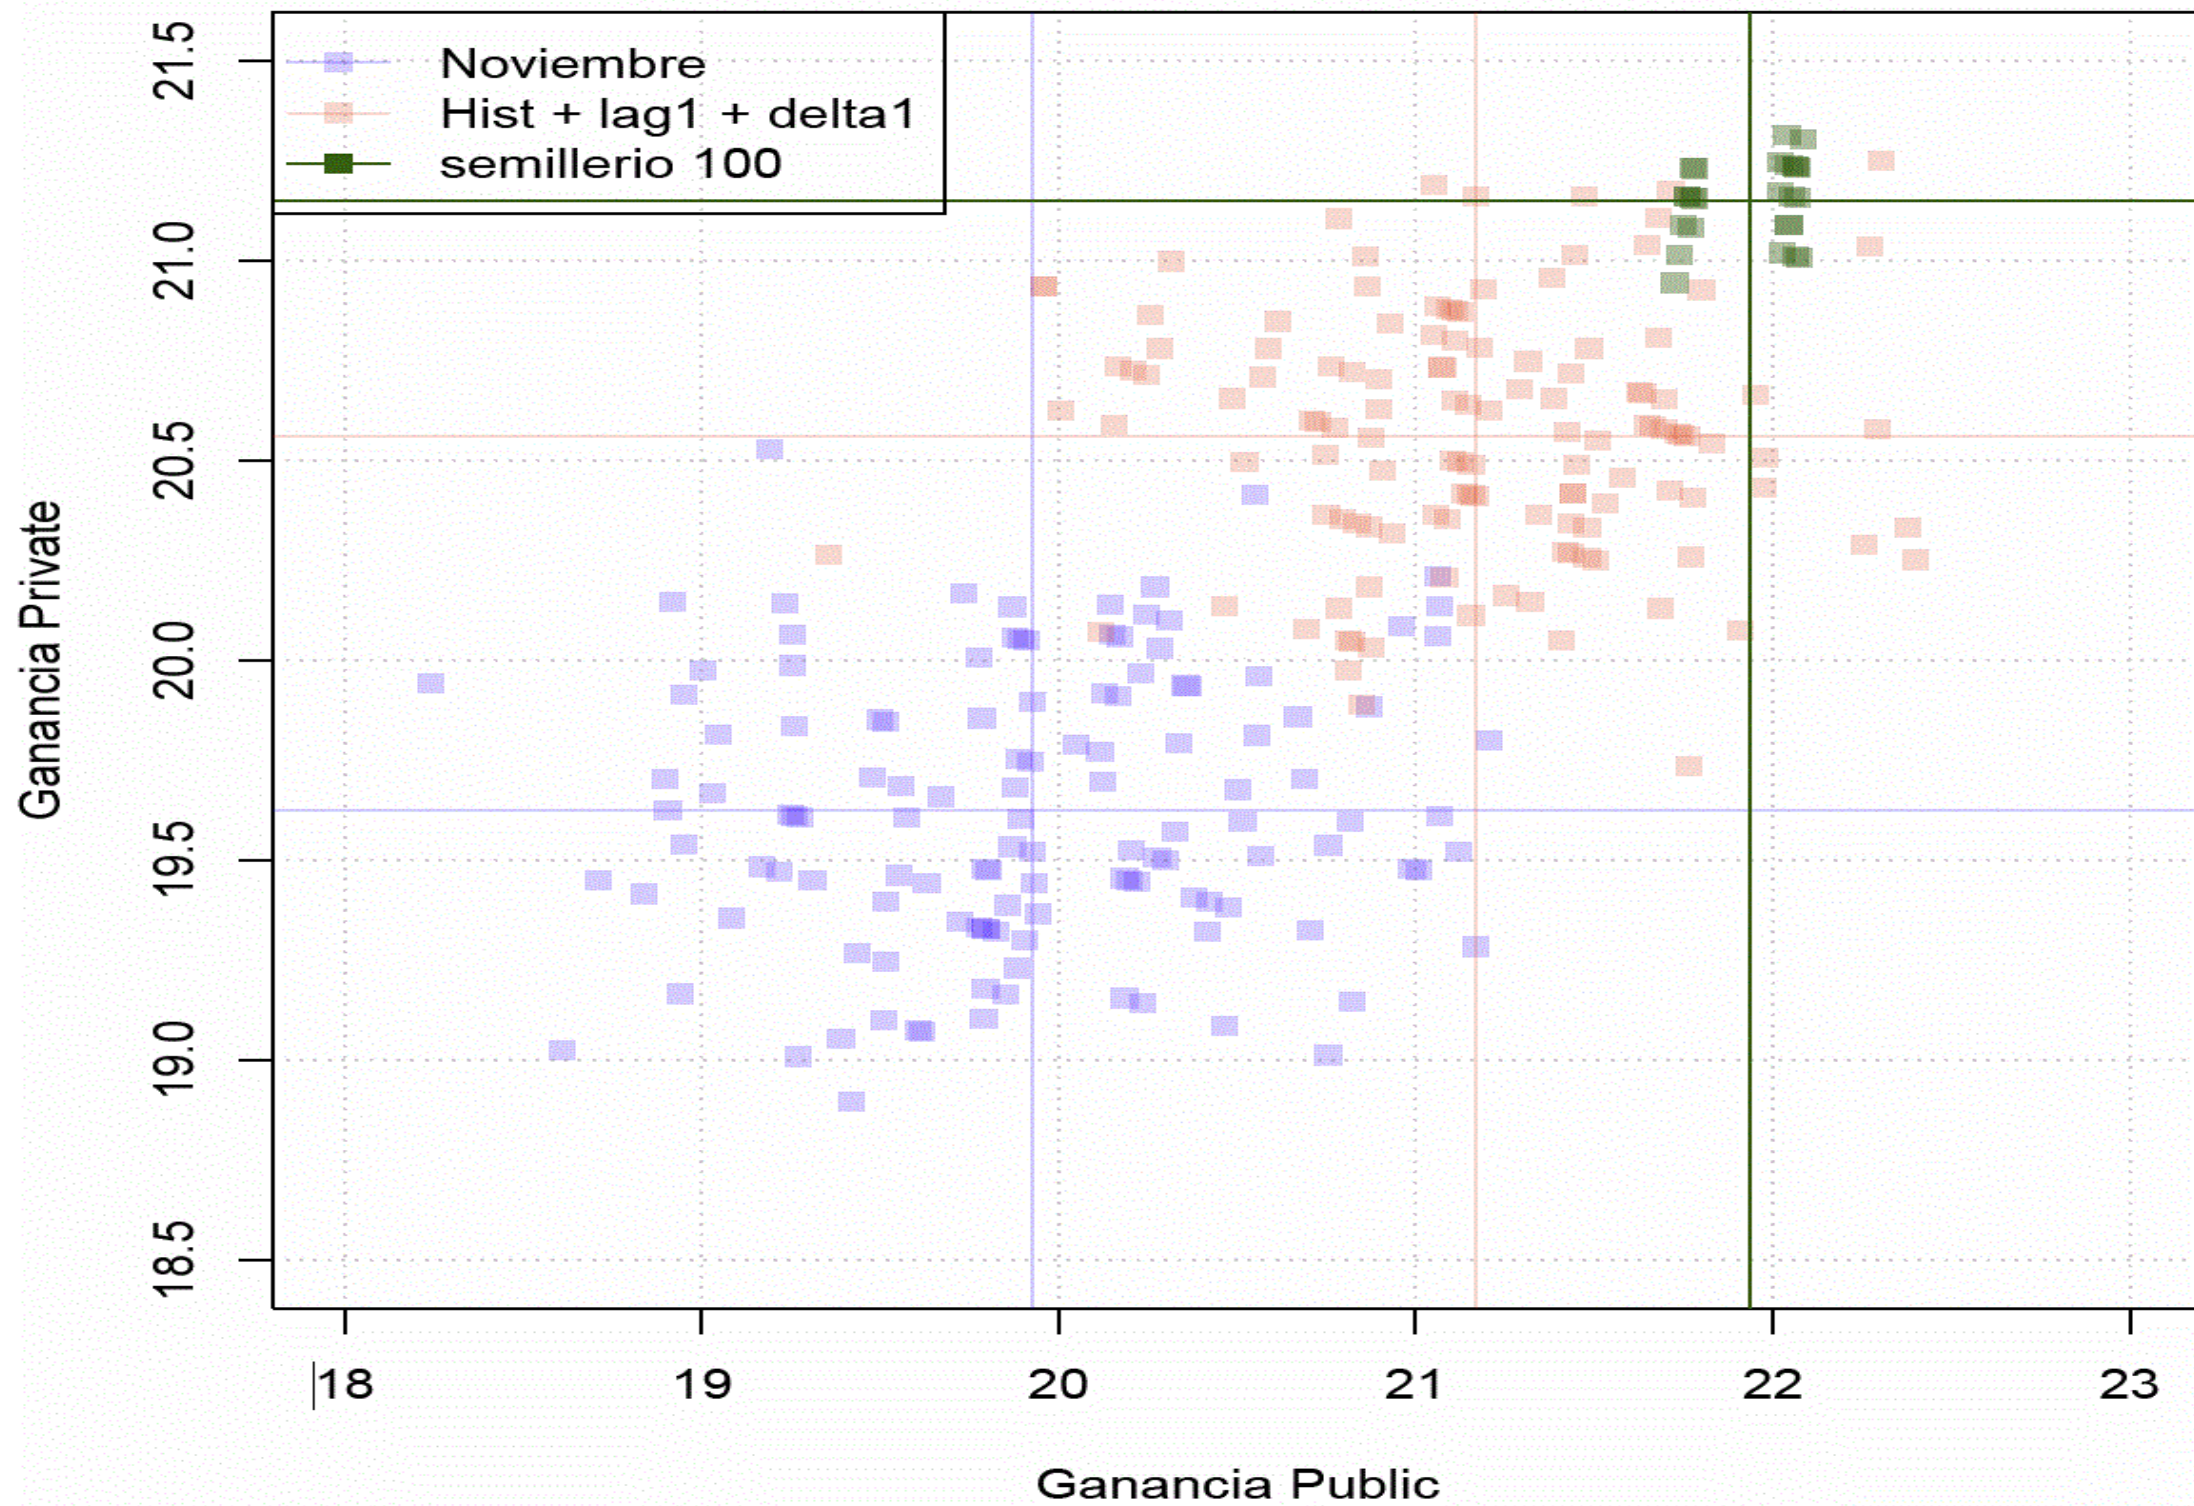


a continuación, para el *Modelo Power*  
se generaron 20 semilleros,  
cada uno con 100 semillas

2000 nuevas semillas

2000 LightGBMs, agrupados en packs de a 100  
cada pack es llamado “Semillero”

*Modelo Simple, Modelo Power, Semillerio-100 de Modelo Power*



Los puntos verdes,  
*Semillero-100 de Modelo Power*  
no solo tiene mayor ganancia promedio  
que *Modelo Power*  
sino que además, sensiblemente menor varianza

Ya no van a haber sorpresas en datos nuevos  
No van a haber caídas ni subidas tan pronunciadas  
en el Private Leaderboard


No era nada intuitivo  
que generar un ensemble de LightGBM's  
cambiando solo la semilla  
iba a generar un modelo superador

Incluso, es una idea tan hereje que nadie en su sano  
juicio perdía tiempo en probarla !


Adicionalmente,  
es muy sencillo implementar Semillero

¿Cómo se ve esto en nuestros datos actuales?  
un modelo entrenado en 18 meses  
aplicado a 202107

**sem: 1 Mejor gan prom = 66279460**




**sem: 5 Mejor gan prom = 69496112**





**sem: 20 Mejor gan prom = 70727857**



La curva roja es un “Ensemble Semillero”  
es decir, es un modelo predictivo nuevo

No confundir con la curva Ganancia Promedio, que  
era simplemente el promedio de las ganancias, y no  
era un modelo predictivo

¿Cuál es el siguiente escalón?

**Hibridación de Semilleros ...**

The End